

Procesamiento y Análisis de Datos Masivos

Proyecto 1 — Data Mining

Camila Acosta
Leonardo Isidro
Matias Maravi


Profesor: **Dr. Heider Sanchez**





Definición del problema


Nuestro objetivo es aplicar las técnicas estudiadas en clase para procesar, analizar y extraer conocimiento en la clasificación de películas por ratings.


20 MM de ratings






Share de Ratings y Volumen Total







Distribución de Actividad de Usuarios




Curva de Concentración de Actividad (Lorenz/Pareto)




Top 15 Películas de Calidad Suprema (Pura Proporción)




Distribución de Popularidad de Películas






Matriz Usuario-Película: Densidad vs Sparsity
(138,493 usuarios × 26,744 películas)

Celdas con Ratings




Celdas Vacías


Top 10 Géneros por Volumen en Catálogo



Top 10 Géneros por Interacción de Usuarios



Mapeo de Nichos por Género: Popularidad, Rating Total y Volumen de Catálogo



Dataframes vs RDDs


Top 20 películas por número de ratings (Spark SQL):

movieId	title	num_ratings	avg_rating
296	Pulp Fiction (1994)	67310	4.17
356	Forrest Gump (1994)	66172	4.03
318	Shawshank Redemption, The (1994)	63366	4.45
593	Silence of the Lambs, The (1991)	63299	4.18
480	Jurassic Park (1993)	59715	3.66
260	Star Wars: Episode IV - A New Hope (1977)	54502	4.19
110	Braveheart (1995)	53769	4.04
589	Terminator 2: Judgment Day (1991)	52244	3.93
2571	Matrix, The (1999)	51334	4.19
527	Schindler's List (1993)	50054	4.31
1	Toy Story (1995)	49695	3.92
457	Fugitive, The (1993)	49581	3.99
150	Apollo 13 (1995)	47777	3.87
780	Independence Day (a.k.a. ID4) (1996)	47048	3.37
50	Usual Suspects, The (1995)	47006	4.33
1210	Star Wars: Episode VI - Return of the Jedi (1983)	46839	4.0
592	Batman (1989)	46054	3.4
1196	Star Wars: Episode V - The Empire Strikes Back (1980)	45313	4.19
2858	American Beauty (1999)	44987	4.16
32	Twelve Monkeys (a.k.a. 12 Monkeys) (1995)	44980	3.9

COMPARATIVA DE RENDIMIENTO

DataFrames/Spark SQL: 0.0662 segundos
RDDs (MapReduce): 27.1272 segundos
Speedup (SQL/RDD): 409.48x

Procesamiento en Paralelo




Summary Metrics for 200 Completed Tasks



Muestreo del Dataset


Comparación de Distribuciones



- Se utilizó un muestreo del 20% para reducir el costo computacional.
- El subconjunto mantuvo una distribución similar al dataset original.
- La característica `long-tail` se conservó en el muestreo.
- El sampleo resultó representativo para aplicar las técnicas propuestas.



MinHashing vs Jaccard

Convergencia del Error: Min-Hashing vs Jaccard Exacto




- El error disminuye al aumentar el número de funciones hash.
- Incluso con firmas pequeñas se obtuvieron buenas aproximaciones.
- Con $k = 200$ se alcanzó un error promedio de 0.0014.
- MinHash logró aproximar correctamente la similitud de Jaccard.



MinHashing vs Jaccard



- La mayoría de pares presentan similitudes bajas dentro del dataset.
- El error de aproximación se mantuvo reducido en distintos niveles de similitud.
- Los valores aproximados por MinHash siguieron muy de cerca a la similitud exacta.
- MinHash logró resultados similares a Jaccard con menor costo computacional.



- LSH presenta un trade-off entre recuperar más pares y aumentar el ruido.
- Más bandas reducen falsos negativos, pero incrementan falsos positivos.
- Algunas configuraciones generan demasiados candidatos y aumentan el costo computacional.
- La configuración (50,4) logró el mejor equilibrio entre FP y FN.



- El F1-Score aumentó conforme creció el número de bandas.
- La configuración $(50,4)$ obtuvo el mejor balance entre precisión y recall.
- Configuraciones más agresivas mejoran el recall, pero reducen la precisión.
- Un exceso de falsos positivos puede afectar la calidad de las recomendaciones

LSH-MLIB

```
SPARK_LSH_NUM_HASH_TABLES = 20
LSH_REAL_THRESHOLD = 0.3
SPARK_APPROX_DISTANCE_THRESHOLD = 1.0 - LSH_REAL_THRESHOLD
```

```
lsh = MinHashLSH(
    inputCol="features",
    outputCol="hashes",
    numHashTables=num_hash_tables
)
model = lsh.fit(df)
```

```
=== COMPARACIÓN CONTRA JACCARD REAL ===
Threshold real (sim): 0.3
Threshold LSH (dist): 0.7
TP: 6460
FP: 0
FN: 22
Precision: 1.0000
Recall: 0.9966
F1-score: 0.9983
Pares en común (para error): 6460
MAE (sim): 0.0000
RMSE (sim): 0.0000
```

Reglas de Asociación y Conjuntos Frecuentes

Representamos un usuario como el conjunto de movieid's de películas que calificaron positivamente. Rating ≥ 3.5



FP-Growth de Spark *optimizado*

- Paraleliza el trabajo.
- Simplifica la identificación de ítems.
- Persistencia y Spilling de RDD's





Fig. 5 Parallel FP - Anti Out Of Memory (OOM)

Reglas de Asociación y Conjuntos Frecuentes

FP-Growth de Spark *optimizado*



Experimento	Soporte	Confianza	Lift
Regla 1	0.0671	0.6860	7.0109x
Regla 2	0.0646	0.6733	7.0182x
Regla 3	0.0245	0.4228	7.2864x

Métricas relevantes del experimento

- Lift > 1: Correlación Postiva.
- Confianza cercana al ≥ 0.5
- Se entiende la variación en Soporte y Confianza por la esparcidad de datos y cantidad de películas.

Fig. 6: Extracto de Top 10 Reglas de Asociación con mayor lift


Top 10 reglas de Asociación

ID	Regla (Antecedente → Consecuente)	Sop.	Conf.	Lift
1	{X-Men, LotR: Two Towers} → X2	0.0355	0.6110	10.52x
2	{X-Men, Matrix} → X2	0.0276	0.4750	8.18x
3	{Lock, Stock...} → <i>Snatch</i>	0.0403	0.5622	7.84x
4	{Monsters Inc, Pirates Caribbean} → <i>Nemo</i>	0.0695	0.7242	7.54x
5	{Incredibles, Shrek} → <i>Nemo</i>	0.0672	0.7003	7.29x
6	{X-Men} → <i>X2: X-Men United</i>	0.0245	0.4228	7.28x
7	{Sin City, Pulp Fiction} → <i>Kill Bill V1</i>	0.0607	0.6550	7.07x
8	{Monsters Inc, Shrek} → <i>Nemo</i>	0.0646	0.6733	7.01x
9	{Finding Nemo, Toy Story} → <i>Monsters Inc</i>	0.0671	0.6860	7.01x
10	{Alien, Star Wars, Terminator...} → <i>Aliens</i>	0.0975	0.8247	6.97x

- Correlación evidente entre películas del mismo Género como: Acción, Aventura, Comedia.
- Surge la duda si la asociación entre secuelas de películas aporta valor o sesga los resultados.


Discusión y Reflexión

- MinHash y LSH redujeron drásticamente el costo computacional manteniendo buena precisión.
- MinHash logró aproximaciones precisas ajustando el tamaño de la firma.
- LSH aceleró la búsqueda de candidatos, aunque introdujo un trade-off entre falsos positivos y falsos negativos.
- Spark mejoró el rendimiento mediante procesamiento distribuido y particionamiento paralelo.



Discusión y Reflexión

- El principal cuello de botella fue el uso de memoria y el shuffling de datos en el clúster.
- FP-Growth permitió descubrir patrones de consumo de forma escalable y sin problemas de memoria.
- Las reglas de asociación mostraron fuertes relaciones entre secuelas y películas de géneros similares.
- Plataformas como Netflix, Spotify y Amazon priorizan baja latencia y escalabilidad sobre exactitud absoluta.



THANK YOU!

OBRIGADO!

¡GRACIAS!

